



Московский государственный университет имени М.В. Ломоносова
Факультет вычислительной математики и кибернетики
Кафедра автоматизации научных исследований

Ким Ренат Ренатович

**Применение методов анализа данных
к задачам распознавания синдромов
по электрокардиограммам**

Выпускная квалификационная работа

Научный руководитель:
д.ф.-м.н., профессор
Сычугов Д. Ю.

Москва, 2026

Аннотация

Сердечно-сосудистые заболевания остаются одной из ведущих причин смертности, а электрокардиография является одним из наиболее доступных и клинически значимых инструментов функциональной диагностики [1]. Вместе с тем автоматическая интерпретация 12-канальных ЭКГ-записей по-прежнему связана с рядом практических трудностей. В этой связи особую актуальность приобретает разработка интерпретируемых вычислительных методов, позволяющих переходить от исходной записи к устойчивому признаковому пространству, пригодному для последующей автоматической классификации.

Целью данной работы является разработка интерпретируемого подхода к автоматическому распознаванию многометочных диагностических суперклассов по 12-канальной ЭКГ на основе поэтапной схемы: сегментация сигнала, морфологическая кластеризация сегментов сердечного цикла и итоговая многометочная классификация. В качестве источника данных использована открытая база РТВ-XL [9]. После прикладной фильтрации в вычислительном эксперименте использовано 21430 записей, из которых 17111 относятся к обучающей части, 2156 к валидационной и 2163 к тестовой. В рамках классификационного этапа рассматриваются пять наиболее представленных суперклассов: NORM, MI, STTC, CD и НУР.

Ключевым обстоятельством является то, что в предложенной схеме классификация строится не напрямую по исходному сигналу, а по промежуточному структурированному представлению, формируемому на основе физиологически осмысленных элементов P-QRS-T-цикла. На этапе делинеации реализована вычислительно устойчивая SWT-адаптация вейвлет-подхода Li-Zheng-Tai [6] с опорой на усреднённый сигнал грудных отведений V1-V6 и последующим переносом найденных границ на исходную многоканальную запись. Внутренний контроль качества сегментации на подвыборке из 80 записей показал высокое среднее покрытие: доля успешно найденных P-волн составила 0.944, T-волн 0.933.

После этапа делинеации выполнена отдельная кластеризация P-, QRS- и T-сегментов по многоканальному корреляционному критерию с дополнительным учётом энергетических характеристик [13]. Для обучения кластерной части обработано 17006 записей обучающей выборки; сформировано 202184 образца P-волн, 205342 образца QRS-комплексов и 200624 образца T-волн. На этой основе построено агрегированное признаковое описание записи размерности 388 признаков, включающее частотные, бинарные, биграммные и статистические характеристики кластерных состояний.

В качестве итогового классификатора использовано одно интерпретируемое

многометочное дерево решений с собственным критерием расщепления по стабильности меток. На тестовой выборке получены следующие сводные результаты: subset accuracy 0.403, Hamming accuracy 0.781, точность 0.516, полнота 0.661 и F1-мера 0.579. Наиболее высокий показатель получен для суперкласса NORM ($F1 = 0.797$), сбалансированный результат наблюдается для STTC ($F1 = 0.649$), а наиболее сложным для распознавания оказался суперкласс HYP ($F1 = 0.399$).

Была проведена работа по анализу устойчивости сегментации, структуры кластеров и качества классификации на обучающей, валидационной и тестовой подвыборках. Полученные результаты показывают, что предложенный подход обеспечивает работоспособную и интерпретируемую схему автоматического анализа ЭКГ и может рассматриваться как практическая основа для дальнейшего развития систем поддержки принятия врачебных решений в задачах многометочной кардиодиагностики.

Оглавление

Введение	5
1 Методы сегментации ЭКГ-сигнала	7
2 Кластеризация кардиоциклов	13
3 Классификация на основе кластерного признакового описания записи	18
4 Практическая схема предлагаемого подхода	22
5 Результаты вычислительного эксперимента и их обсуждение	28
Заключение	38
Литература	39

Введение

Сердечно-сосудистые заболевания остаются одной из ведущих причин смертности в мире, что определяет высокую значимость методов их своевременного выявления и автоматизированного анализа клинических данных. Электрокардиография является одним из основных и наиболее доступных инструментов функциональной диагностики сердечно-сосудистой системы. Электрокардиограмма представляет собой регистрацию электрической активности сердца путём записи разностей электрических потенциалов электродов, размещённых на поверхности тела. Она широко используется для выявления ранних нарушений ритма, проводимости, ишемических изменений и других патологических состояний J. R. Hampton [1]. В современных условиях рост объёма регистрируемых ЭКГ, в том числе за счёт мобильных систем мониторинга, и необходимость более стабильного выявления отклонений делают особенно актуальной разработку алгоритмов автоматической интерпретации сигналов.

Стоит отметить, что ЭКГ-сигнал обладает сложной структурой (в данной работе будем рассматривать классическую двенадцатиканальную запись). В обзорных исследованиях по обработке ЭКГ подчёркивается, что такие сигналы являются нестационарными, нелинейными и подверженными влиянию шумов и артефактов [2]. В этой связи ключевое значение приобретает построение информативного представления сигнала, пригодного для последующего применения методов машинного обучения. Извлечение признаков и сокращение размерности рассматриваются как необходимые этапы построения устойчивых диагностических систем, поскольку позволяют выделять существенные характеристики сигнала и уменьшать влияние избыточной информации [2].

Среди классических методов анализа ЭКГ широко применяются вейвлет-подходы и другие методы частотно-временного анализа [6]. Однако их выходные представления нередко слабо интерпретируемы с клинической точки зрения, в отличие от представлений, основанных на выделении физиологически осмысленных элементов сердечного цикла. Близким к реальному циклу анализа ЭКГ является сегментация сигнала. В ряде случаев она является почти достаточным методом для построения информативного пространства признаков. Например, для задач детектирования аритмий особое значение имеет обнаружение R-пигов, поскольку по ним определяются RR-интервалы, отражающие временную организацию сердечной деятельности [7]. После получения RR-интервалов можно разметить P–QRS–T-комплекс или собрать общие статистические данные о цикле.

В литературе встречаются работы, в которых RR-интервалы используются как самостоятельные паттерны для последующей кластеризации и классификации. В частности, в исследовании по кластеризации аритмий методом *vague c-means* использовался набор паттернов, представляющих собой RR-интервалы, полученные после детекции R-пигов и нормализации [8].

Кластеризация кардиологических данных представляет интерес как средство выделения типовых состояний сигнала. Кластерный анализ позволяет выявлять повторяющиеся структуры и объединять схожие фрагменты ЭКГ. Это особенно важно в задачах, где исходный сигнал обладает высокой внутриклассовой вари-

ативностью, а одна и та же патология может проявляться в нескольких морфологических вариантах. В таком случае кластеризация RR-интервалов может рассматриваться как способ перехода от высокоразмерного описания ЭКГ к последовательности дискретных состояний, отражающих типовые формы сердечных циклов.

Дополнительную актуальность рассматриваемой задаче придаёт многометочная природа клинической диагностики. Одна запись ЭКГ может одновременно содержать несколько диагностически значимых признаков, относящихся к нарушениям ритма, проводимости, ишемическим изменениям или другим синдромам. Существенную роль в развитии подобных методов сыграло появление крупных открытых баз с многоуровневой диагностической разметкой, в частности РТВ-ХЛ и SPH [9, 10]. Кроме того, современные модели уже ориентируются на большое число диагностических терминов; например, в работе Lai et al. рассматривается распознавание 254 иерархически организованных меток [11]. Следовательно, построение моделей, ориентированных только на бинарную или однометочную классификацию, не полностью соответствует реальным диагностическим целям.

Таким образом, актуальной является задача построения пространства признаков, на котором может быть обучена интерпретируемая модель классического машинного обучения с ограниченной сложностью. В настоящей работе рассматривается задача автоматического распознавания многометочных диагностических суперклассов по ЭКГ; её решение основывается не на непосредственной классификации исходного сигнала, а на поэтапном структурном преобразовании записи. Логика такого подхода заключается в последовательном переходе от непрерывной записи к физиологически интерпретируемым элементам, затем к их типовым морфологическим состояниям и далее — к классификации сформированного кластерного признакового описания записи. Такая схема позволяет объединить преимущества сегментации, морфологической кластеризации и интерпретируемого машинного обучения.

Целью данной работы является разработка интерпретируемого подхода к автоматическому распознаванию многометочных диагностических суперклассов по 12-канальной ЭКГ на основе сегментации сигнала, морфологической кластеризации *P*-, *QRS*- и *T*-фрагментов и последующей классификации сформированного кластерного признакового описания записи.

Объектом исследования являются двенадцатиканальные электрокардиографические записи, содержащие информацию о сердечном ритме и патологических состояниях сердечно-сосудистой системы.

Практическая значимость работы заключается в разработке подхода, ориентированного на построение более компактного и интерпретируемого представления ЭКГ-сигнала. Такое представление пригодно для автоматической диагностики в условиях больших массивов данных и многометочной клинической разметки.

Глава 1

Методы сегментации ЭКГ-сигнала

Сегментация ЭКГ-сигнала в рамках данной работы рассматривается как ключевой этап перехода от исходной записи к структурированному представлению сердечной деятельности, пригодному для последующей кластеризации и классификации. На этом этапе сигнал разбивается на физиологически осмысленные фрагменты, прежде всего на отдельные кардиоциклы, соответствующие RR -интервалам. Границы последних задаются положением R -пиков. Корректность такой сегментации непосредственно влияет на качество всех последующих шагов: вычисления временных и энергетических характеристик цикла, формирования кластеров и построения устойчивой модели распознавания синдромов. При более детальной постановке задача сегментации включает также делинеацию волн P , QRS и T и выделение их характерных точек; как отмечается в работах по вейвлет-делинеации ЭКГ, такое описание позволяет перейти от общей ритмовой структуры записи к клинически интерпретируемым параметрам сигнала [3, 6].

В данном разделе рассматриваются три характерных подхода: классический алгоритм Pan–Tompkins как базовый метод QRS-детекции [7], алгоритм Christov как более адаптивная схема обнаружения QRS [5], а также подход Li, Zheng и Tai, основанный на вейвлет-преобразовании, как переход к полноценной сегментации характерных точек ЭКГ [6].

Алгоритм Pan–Tompkins

Алгоритм, предложенный в статье *A Real-Time QRS Detection Algorithm*, является одним из наиболее известных классических методов детекции комплекса QRS [7]. Его цель состоит в надёжном обнаружении QRS -комплексов в реальном времени на основе анализа наклона, амплитуды и ширины комплекса. Авторы подчёркивают, что одной производной недостаточно, поскольку она усиливает влияние высокочастотного шума и может пропускать широкие аномальные комплексы с малым наклоном, поэтому в алгоритм включается последовательность нескольких преобразований сигнала.

Этапы алгоритма включают:

1. Полосовую фильтрацию для комплекса QRS
2. Вычисление производной, показывающее наклон фронта сигнала
3. Возведение в квадрат результата предыдущего пункта $y(nT) = [x(nT)]^2$
4. Применение скользящего интегрирования $s(nT) = \frac{1}{N} \sum_{k=0}^{N-1} y(nT - kT)$
5. Принятие решения о наличии QRS по адаптивным порогам, вычисляемым на основе текущих оценок сигнальных и шумовых пиков
6. Принятие решения о наличии QRS по двум наборам адаптивных порогов (для отфильтрованной ЭКГ и для сигнала после скользящего интегрирования).
7. Поиск пропущенных комплексов: если QRS не обнаружен в течение среднего RR -интервала, применяется пониженный порог и выбирается максимальный пик.

Дополнительно предлагается использовать информацию о RR -интервалах и их ожидаемых периодах для поиска пропущенных комплексов и различения QRS -комплексов и T -волн [7].

Для целей настоящей работы алгоритм Pan–Tompkins важен прежде всего как исходная классическая схема детекции R -пиков. Однако его возможности ограничены: он ориентирован на один анализируемый канал сигнала, а его результатом является в первую очередь обнаружение QRS -комплекса, а не полная разметка волн P , QRS и T .

Алгоритм Christov

В статье *Real time electrocardiogram QRS detection using combined adaptive threshold* предложен более адаптивный подход к детекции QRS -комплексов [5]. В отличие от Pan–Tompkins, где ключевую роль играет последовательность фильтрации и нелинейных преобразований, здесь центральным объектом является *комбинированный адаптивный порог*, который в каждый момент времени подстраивается под текущую крутизну сигнала, уровень высокочастотного шума и ожидаемое положение следующего сердечного сокращения. Тем самым задача обнаружения QRS формулируется как сравнение специального производного сигнала с динамически изменяющейся границей решения.

Первым шагом строится комплексное отведение

$$Y(i) = \frac{1}{L} \sum_{j=1}^L |X_j(i+1) - X_j(i-1)|,$$

где L — число используемых отведений, а $X_j(i)$ — значение ЭКГ-сигнала в j -м канале в момент времени i . Эта величина представляет собой усреднённую по каналам оценку локальной скорости изменения сигнала. При этом использование нескольких отведений делает алгоритм более устойчивым в условиях, когда морфология комплекса отличается по полярности и амплитуде в разных каналах.

После предобработки решение о наличии комплекса QRS принимается по правилу

$$Y(i) \geq MFR(i),$$

где комбинированный порог задаётся суммой

$$MFR = M + F + R.$$

Компонента M (*steep-slope threshold*) отвечает за типичную крутизну фронтов недавно обнаруженных комплексов. В начальный момент она задаётся как

$$M = 0.6 \cdot \max(Y),$$

после чего обновляется по максимуму сигнала в окрестности найденного комплекса и затем постепенно уменьшается во времени. Компонента F (*integrating threshold*) предназначена для подавления ложных срабатываний на высокочастотный шум. Она вычисляется как динамическая оценка активности сигнала в скользящем окне и увеличивает общий порог при росте электромиографических помех. Наконец, компонента R использует информацию о последних RR -интервалах и уменьшает эффективный порог в ожидаемый момент появления очередного комплекса. Тем самым Christov объединяет в одной формуле морфологическую информацию, шумовую обстановку и априорную ритмовую структуру сигнала [5].

С математической точки зрения достоинство метода Christov состоит в том, что он заменяет фиксированное пороговое решение функционалом вида

$$Y(i) \geq M(i) + F(i) + R(i),$$

в котором каждая слагаемая адаптивно меняется во времени. Такой подход особенно полезен для шумных ЭКГ и для длительного мониторинга. Однако, как и Рап–Томпкинс, этот алгоритм в первую очередь решает задачу детекции QRS -комплексов и R -пиков, но не задаёт механизмов полной делинеации волн P , QRS и T . Поэтому для решения поставленной задачи этот алгоритм не подходит в классическом его варианте.

Вейвлет-подход Li, Zheng и Tai

Переход от обнаружения комплекса QRS к сегментации характерных точек ЭКГ реализован в статье *Detection of ECG Characteristic Points Using Wavelet Transforms* [6]. В этой работе задача ставится уже существенно шире: требуется не только локализовать QRS -комплекс, но и определить характерные точки P - и T -волн, а также начала и окончания соответствующих сегментов. Ключевая идея состоит в том, что вейвлет-преобразование позволяет анализировать сигнал сразу в нескольких масштабах, а значит, выделять как быстрые компоненты, соответствующие QRS -комплексу, так и более медленные компоненты, соответствующие P - и T -волнам.

Исходное вейвлет-преобразование вводится в стандартной форме

$$W_s f(x) = f * \psi_s(x) = \frac{1}{s} \int_{-\infty}^{+\infty} f(t) \psi\left(\frac{x-t}{s}\right) dt,$$

где s — масштаб, а ψ_s — вейвлет-функция. На практике используется схема масштабов

$$s = 2^j, \quad j \in \mathbb{Z},$$

что даёт семейство вейвлет-коэффициентов $W_{2^j}f(n)$. В оригинальной схеме такие коэффициенты могут вычисляться по Mallat через рекуррентные соотношения [4]

$$S_{2^j}f(n) = \sum_{k \in \mathbb{Z}} h_k S_{2^{j-1}}f(n - 2^{j-1}k),$$

$$W_{2^j}f(n) = \sum_{k \in \mathbb{Z}} g_k S_{2^{j-1}}f(n - 2^{j-1}k),$$

где h_k и g_k — коэффициенты сглаживающего и вейвлет-фильтра соответственно. С математической точки зрения это означает, что сигнал разлагается на набор компонент различных масштабов, каждая из которых отвечает определённому диапазону временных изменений.

В качестве анализирующей волновой функции предлагается использовать квадратичный сплайновый вейвлет (*quadratic spline wavelet*) с компактным носителем и одним исчезающим моментом [6]. Такой выбор связан не только с удобством вычислений, но и с тем, как именно этот вейвлет реагирует на форму ЭКГ-сигнала. Поскольку рассматриваемая волновая функция является первой производной гладкой сглаживающей функции, её отклик максимален не на медленно меняющихся участках записи, а на резких фронтах, характерных прежде всего для комплекса *QRS*.

В оригинальной статье показано, что для однополярной волны на фиксированном масштабе восходящему фронту соответствует отрицательный минимум вейвлет-коэффициентов, а нисходящему — положительный максимум; таким образом формируется пара экстремумов, между которыми нуль-пересечение задаёт положение пика волны. Для симметричной формы это соответствие практически точное, а для асимметричной остаётся достаточно точным на малых масштабах, что и делает возможной локализацию характерных точек по структуре коэффициентов, а не только по амплитуде исходного сигнала [6]. Наличие одного исчезающего момента, в свою очередь, уменьшает чувствительность преобразования к постоянной составляющей и медленным изменениям изолинии, то есть помогает отделять морфологически значимые переходы от фонового дрейфа. Поэтому в данном подходе геометрия локальных максимумов, минимумов и нуль-пересечений вейвлет-коэффициентов оказывается напрямую связанной с геометрией самих волн ЭКГ и может использоваться как основа для делинеации сердечного цикла.

Наиболее подробно эта идея развивается в более позднем разборе и реализации вейвлет-сегментации в работе *ECG Signal Analysis based on the Wavelet Transform* [3]. Там для практической делинеации используется уже стационарное дискретное вейвлет-преобразование и *biorthogonal quadratic spline wavelet*, заданный через decomposition filters

$$l_{\text{dec}}[n] = \frac{1}{8}\delta[n+2] + \frac{3}{8}\delta[n+1] + \frac{3}{8}\delta[n] + \frac{1}{8}\delta[n-1],$$

$$h_{\text{dec}}[n] = 2(\delta[n+1] - \delta[n]).$$

Такой выбор базиса разложения особенно удобен, поскольку он даёт линейно-фазовые эквивалентные фильтры, а значит, делает связь между экстремумами сигнала и нуль-пересечениями вейвлет-коэффициентов более устойчивой и интерпретируемой. Кроме того, в этой работе подробно показано, как коэффициенты разных масштабов d_1, d_2, d_3, d_4 соотносятся с различными компонентами ЭКГ: малые масштабы лучше подходят для QRS -комплекса, а более крупные — для P - и T -волн [3].

В статье Li, Zheng и Tai детекция комплекса QRS строится на анализе так называемых *modulus maxima lines*, то есть линий максимумов модуля вейвлет-коэффициентов на нескольких масштабах [6]. Авторы показывают, что для характерной однополярной волны положительный максимум и отрицательный минимум вейвлет-коэффициентов образуют пару, а нуль-пересечение между ними соответствует локальному экстремуму сигнала. Таким образом, R -пик не ищется напрямую по амплитуде сигнала, а восстанавливается через многомасштабную структуру максимумов и нуль-пересечений.

Практически это означает, что информация о комплексе QRS в основном сосредоточена на промежуточных масштабах, прежде всего на 2^3 и 2^4 . Сначала значимые максимумы определяются на более крупных масштабах, где влияние шума меньше, после чего их положение уточняется на масштабе 2^1 , обладающем лучшей временной точностью. Такая схема отражает общий принцип вейвлет-сегментации: крупные масштабы дают устойчивость, малые — точность локализации [6].

После нахождения R -пиков алгоритм переходит к определению начала и конца комплекса QRS . Для этого анализируется структура вейвлет-коэффициентов на масштабе 2^1 , поскольку именно он лучше всего отражает быстрые низкоамплитудные компоненты Q - и S -волн. Начало комплекса трактуется как начало волны Q , а при её отсутствии — как начало R -волны; окончание комплекса определяется аналогично по S -волне или по окончанию R -волны. Таким образом, R -пик служит якорной точкой, относительно которой восстанавливаются границы комплекса.

Детекция T - и P -волн строится на более крупных масштабах. Авторы показывают, что энергия этих волн лучше всего проявляется на масштабах 2^4 и 2^5 , однако на масштабе 2^5 заметно усиливается влияние дрейфа изолинии, поэтому для практической работы выбирается масштаб 2^4 . Затем для T -волны задаётся временное окно после найденного R -пика, а для P -волны — окно перед ним. Внутри этих окон также ищутся пары максимумов и минимумов вейвлет-коэффициентов, по которым определяются пики, начала и окончания соответствующих волн. Тем самым строится уже не просто детектор R -пиков, а полноценный алгоритм delineации сердечного цикла [6].

С математической точки зрения достоинство подхода Li, Zheng и Tai состоит в том, что он объединяет три важных свойства. Во-первых, вейвлет-разложение даёт многомасштабное представление сигнала, естественным образом согласованное с различной длительностью QRS , P - и T -волн. Во-вторых, использование локальных максимумов и нуль-пересечений позволяет перейти от анализа амплитуды к

анализу геометрии сигнала. В-третьих, сегментация строится относительно уже найденного R -пика, что обеспечивает структурную связность всех последующих этапов делинеации. В настоящей работе данный подход используется как методологическая основа, однако практическая реализация является адаптацией: применяется стационарное вейвлет-преобразование SWT с биортогональным базисом bior2.2, а не буквальное воспроизведение исходного dyadic wavelet transform.

Выводы

Рассмотренные методы представляют три различных уровня постановки задачи сегментации ЭКГ. Алгоритм Pan–Tompkins является классическим и вычислительно простым одноканальным детектором комплекса QRS , полезным прежде всего как базовый инструмент выделения R -пиков. Алгоритм Christov развивает ту же линию методов, вводя более гибкую адаптивную схему обнаружения, в которой одновременно учитываются морфология сигнала, уровень высокочастотного шума и ожидаемое положение следующего удара. Однако оба этих подхода ориентированы главным образом на детекцию QRS -комплексов и не обеспечивают полноценной сегментации волн P , QRS и T .

В отличие от них подход Li, Zheng и Tai, основанный на вейвлет-преобразовании, естественным образом расширяет постановку задачи до полной делинеации сердечного цикла. Использование разложения по масштабам и анализ вейвлет-коэффициентов позволяют связать геометрию ЭКГ с геометрией её многомасштабного представления и тем самым перейти от простой детекции R -пика к выделению структурированных сегментов сигнала. Для дальнейших задач, связанных с представлением сердечных циклов, их кластеризацией и последующей классификацией, именно вейвлет-сегментация представляется наиболее содержательной основой.

Глава 2

Кластеризация кардиоциклов

Кластеризация в контексте настоящей работы рассматривается как промежуточный этап между сегментацией ЭКГ и последующей многометочной классификацией записи. Её задача состоит не просто в разбиении выделенных фрагментов сигнала на группы похожих объектов, а в построении пространства типовых морфологических состояний, с помощью которого непрерывная многоканальная запись может быть преобразована в более компактное и физиологически интерпретируемое представление. Такой переход особенно важен для дальнейшего анализа, поскольку позволяет связать признаки классификации со структурой сердечного цикла, а не только с абстрактными числовыми характеристиками.

Основной интерес в данной главе представляет кластеризация морфологии отдельных волн и комплексов ЭКГ. В отличие от кластеризации RR -интервалов, ориентированной преимущественно на анализ ритмической структуры сигнала [8], морфологическая кластеризация направлена на выявление типовых форм локальных электрокардиографических событий. Такая постановка является более содержательной с точки зрения последующего диагностического анализа, поскольку позволяет учитывать не только интервальные характеристики, но и особенности формы сегментированных компонентов сердечного цикла. Прежде всего речь идёт о QRS -комплексах и, при наличии достаточно надёжной делинеации, о P - и T -волнах [6, 3].

С математической точки зрения после сегментации каждому выделенному компоненту фиксированного типа можно сопоставить многоканальный паттерн

$$x_j^{(W)} = (x_{j,1}^{(W)}, x_{j,2}^{(W)}, \dots, x_{j,L}^{(W)}), \quad x_{j,\ell}^{(W)} \in \mathbb{R}^{d_W},$$

где $W \in \{P, QRS, T\}$ обозначает тип сегмента, L — число используемых отведений, d_W — длина фрагмента после выравнивания, а j — номер наблюдаемого объекта. Тогда задача кластеризации состоит в построении разбиения множества

$$S_W = \{x_1^{(W)}, x_2^{(W)}, \dots, x_n^{(W)}\}$$

на подмножества, соответствующие устойчивым морфологическим типам. В такой постановке кластер интерпретируется не как абстрактная группа похожих векторов, а как типовая форма сегментированного электрокардиографического объекта.

Многоканальная корреляционная кластеризация QRS -комплексов

Наиболее прямой и практически реализованный подход к кластеризации морфологии ЭКГ представлен в работе Plesinger et al. [13]. В данной постановке кластеризация рассматривается как обязательный этап предобработки перед дальнейшим усреднением и анализом сигнала. Основная идея метода состоит в том, что внутри одной записи могут присутствовать несколько различных морфологических типов QRS -комплексов, и их предварительное разделение необходимо для получения устойчивых усреднённых представлений.

Входом алгоритма в оригинальной работе служат сигналы в отведениях $V1$ – $V6$ и список ранее обнаруженных QRS -аннотаций, то есть фактически $L = 6$ [13]. Для каждого комплекса формируется временное окно фиксированной длины, центрированное относительно текущей аннотации; в статье используется окно ± 120 мс [13]. Если два сегмента одного и того же отведения обозначить через

$$a = (a_1, \dots, a_N), \quad b = (b_1, \dots, b_N),$$

то их морфологическое сходство оценивается с помощью коэффициента корреляции Пирсона:

$$\rho(a, b) = \frac{\sum_{k=1}^N (a_k - \bar{a})(b_k - \bar{b})}{\sqrt{\sum_{k=1}^N (a_k - \bar{a})^2} \sqrt{\sum_{k=1}^N (b_k - \bar{b})^2}},$$

где

$$\bar{a} = \frac{1}{N} \sum_{i=1}^N a_i, \quad \bar{b} = \frac{1}{N} \sum_{i=1}^N b_i.$$

Поскольку сравнение выполняется сразу по нескольким отведениям, для двух многоканальных комплексов q_r и q_s вводится агрегированная мера сходства

$$C_{\min}(q_r, q_s) = \min_{\ell=1, \dots, L} \rho(q_r^{(\ell)}, q_s^{(\ell)}),$$

где $q_r^{(\ell)}$ и $q_s^{(\ell)}$ — формы соответствующих комплексов в ℓ -м отведении. Использование минимума по каналам означает, что два комплекса считаются морфологически близкими только в том случае, если их форма согласована во всех рассматриваемых отведениях, а не только в одном из них.

Процедура кластеризации строится итеративно. Первый обнаруженный комплекс принимается в качестве первого элемента первой морфологической группы. Затем каждый следующий нераспределённый комплекс сравнивается с уже распределёнными комплексами. Если для некоторой группы выполняется условие

$$C_{\min}(q_r, q_s) > C_t,$$

где C_t — порог корреляции, то комплекс присоединяется к этой группе. В противном случае создаётся новая группа. Таким образом, разбиение строится не

через поиск центров в евклидовом пространстве признаков, а как последовательное формирование групп на основе многоканального критерия морфологического сходства. В статье Plesinger et al. начальный порог выбирается равным 0.98, а при избыточном числе групп он может постепенно уменьшаться вплоть до нижней границы 0.75, после чего выполняется повторный запуск процедуры [13].

Существенной особенностью метода является наличие этапа коррекции временного смещения аннотаций внутри каждой группы. Даже близкие по форме комплексы могут быть немного смещены друг относительно друга, и без устранения этого смещения дальнейшее усреднение приведёт к размыванию морфологических деталей. В оригинальной работе в качестве опорного элемента используется первый представитель группы [13]. Если его обозначить через $q_{\text{ref},i}$, то для j -го комплекса внутри i -й группы ищется такой сдвиг τ , который максимизирует сходство с опорной формой:

$$\tau_j^* = \arg \max_{\tau \in \mathcal{T}} \min_{\ell=1,\dots,L} \rho\left(q_j^{(\ell)}(t - \tau), q_{\text{ref},i}^{(\ell)}(t)\right),$$

где $\mathcal{T}$ — множество допустимых малых временных сдвигов. После этого все комплексы внутри группы приводятся к единой временной привязке.

Следующим этапом является построение усреднённой многоканальной формы кластера. В статье она называется *group average multi-lead shape* (GAMS) [13]. Если G_i — множество индексов комплексов, вошедших в i -й кластер, то усреднённый шаблон в ℓ -м отведении определяется как

$$\bar{q}_i^{(\ell)}(t) = \frac{1}{|G_i|} \sum_{j \in G_i} q_j^{(\ell)}(t - \tau_j^*).$$

Полученная функция $\bar{q}_i^{(\ell)}(t)$ представляет собой типовую форму соответствующего морфологического класса. Именно на этом шаге кластер приобретает физиологически интерпретируемый смысл: он становится усреднённым описанием определённого типа *QRS*-морфологии.

После построения усреднённых форм выполняется дополнительная проверка на избыточность числа кластеров. Если две группы оказываются практически одинаковыми по форме, но отличаются лишь небольшим относительным временным сдвигом, они объединяются. Для этого сравниваются уже не отдельные комплексы, а усреднённые шаблоны:

$$S_{ij} = \max_{\tau \in \mathcal{T}_s} \min_{\ell=1,\dots,L} \rho\left(\bar{q}_i^{(\ell)}(t - \tau), \bar{q}_j^{(\ell)}(t)\right).$$

Если

$$S_{ij} > C_{ts},$$

то группы G_i и G_j объединяются. Таким образом, итоговое разбиение формируется в результате последовательности операций: первичная корреляционная кластеризация, выравнивание аннотаций, построение усреднённых форм и последующая консолидация близких морфологических групп.

Особое место в алгоритме занимает так называемая объединённая группа редких или плохо согласованных объектов. Если некоторая группа содержит слишком малое число элементов, в статье используется правило

$$|G_i| < 3,$$

то она не рассматривается как полноценный морфологический класс и переводится в специальную служебную *Joined Group* [13]. С математической точки зрения это эквивалентно отсечению тех множеств объектов, для которых невозможно построить устойчивый шаблон. Такое решение является оправданным, поскольку единичные или крайне редкие формы в клинических данных часто обусловлены шумом, артефактами записи или нестабильной сегментацией.

Принципиальное достоинство рассматриваемого подхода состоит в том, что он ориентирован именно на морфологию сигнала, а не на заранее заданные диагностические метки. Следует отметить, что коэффициент Пирсона только описывает сходство формы после центрирования сигнала и не отражает знак смещения относительно изолинии. В частности, он инвариантен к добавлению постоянной составляющей и поэтому не позволяет различать, например, элевацию и депрессию сегмента ST при близкой форме сигнала. По этой причине в практической части работы дополнительно вводится знакоориентированная амплитудная характеристика сегмента, позволяющая учитывать направление преобладающего отклонения.

Кластеризация P - и T -волн как естественное расширение метода

С теоретической точки зрения предложенная многоканальная корреляционная схема не зависит от того, какой именно сегмент ЭКГ используется в качестве объекта кластеризации. Единственным необходимым условием является наличие корректно выделенных и временно выровненных повторяющихся фрагментов сигнала. Поэтому после надёжной делинеации та же постановка может быть непосредственно перенесена не только на P -волны, но и на T -волны [6, 3]. Такое расширение согласуется и с общей логикой метода Plesinger et al.: он ориентирован не на конкретный тип волны, а на повторяющиеся морфологические образования, для которых можно задать многоканальную меру сходства формы и выполнить корректное временное выравнивание [13].

Пусть каждая сегментированная волна фиксированного типа $W \in \{P, T\}$ представлена в виде

$$w_j^{(W)} = (w_j^{(W,1)}, w_j^{(W,2)}, \dots, w_j^{(W,L)}), \quad w_j^{(W,\ell)} \in \mathbb{R}^{d_W}.$$

Тогда для пары волн одного и того же типа вводится мера сходства

$$C_{\min}(w_r^{(W)}, w_s^{(W)}) = \min_{\ell=1, \dots, L} \rho(w_r^{(W,\ell)}, w_s^{(W,\ell)}),$$

после чего используется та же логика порогового объединения, коррекции временного смещения и построения усреднённого многоканального шаблона. В результате для каждого типа волны формируется собственное пространство кластеров

$$\mathcal{C}_W = \{1, \dots, K_W\},$$

а каждой сегментированной волне сопоставляется морфологическая метка

$$c_j^{(W)} \in \mathcal{C}_W.$$

Содержательно переход к таким кластерам важен потому, что P - и T -волны отражают различные физиологические фазы сердечного цикла. Если P -волна связана с предсердной деполяризацией, то T -волна характеризует желудочковую реполяризацию. Поэтому в рамках настоящей работы достаточно отметить, что кластеризация T - и P -волн строится полностью аналогично кластеризации QRS волн: меняется только тип анализируемого сегмента и его физиологическая интерпретация, тогда как математическая схема сравнения, выравнивания и усреднения остаётся той же.

Выводы

Таким образом, наиболее содержательной и методически обоснованной постановкой кластеризации ЭКГ в контексте настоящей работы является кластеризация морфологии отдельных сегментированных компонентов сердечного цикла. Математической основой практической схемы выступает корреляционная кластеризация с прототипами, стабилизированная дополнительным критерием signed-energy. Такая постановка сохраняет морфологическую интерпретируемость шаблонов и одновременно снижает риск смещения форм, различающихся знаком преобладающего отклонения.

В результате кластеризация морфологии может быть интерпретирована как переход от непрерывного многоканального сигнала к дискретному пространству типовых форм

$$\mathcal{C}_P, \quad \mathcal{C}_{QRS}, \quad \mathcal{C}_T.$$

Следующий шаг состоит в том, чтобы перейти от меток отдельных волн к кластерному признаковому описанию всей записи. Именно такое представление и будет использовано в следующей главе при постановке задачи многометочной классификации ЭКГ.

Глава 3

Классификация на основе кластерного признакового описания записи

В предыдущей главе было показано, что после сегментации и морфологической кластеризации ЭКГ может быть приведена к более компактному дискретному представлению. На уровне отдельной записи это представление задаётся тремя последовательностями кластерных состояний — для P -, QRS - и T -сегментов, — из которых далее строится конечный вектор признаков. Следовательно, объектом классификации в настоящей главе является уже не исходный многоканальный сигнал и не отдельные сегменты, а кластерное признаковое описание записи, отражающее частоты морфологических состояний, их переходы и связанные с ними агрегированные характеристики.

Такая постановка сохраняет интерпретируемость, поскольку каждая координата признакового вектора связана с конкретным морфологическим паттерном или с простой статистикой последовательности кластерных меток. Именно это позволяет использовать в качестве финальной модели единое многометочное решающее дерево, а не непрозрачную end-to-end архитектуру.

Многометочная постановка задачи классификации

Поскольку одна запись ЭКГ может одновременно содержать несколько диагностически значимых признаков, задача классификации в настоящей работе рассматривается в многометочной постановке. Пусть

$$\mathcal{Y} = \{1, 2, \dots, L\}$$

— фиксированное множество диагностических классов, а каждой записи сопоставлен бинарный вектор

$$y^{(i)} = (y_1^{(i)}, y_2^{(i)}, \dots, y_L^{(i)}) \in \{0, 1\}^L,$$

где $y_j^{(i)} = 1$ означает наличие j -го диагностического класса в i -й записи.

После этапа сегментации и кластеризации каждой записи сопоставляется вектор признаков

$$x^{(i)} \in \mathbb{R}^p,$$

сформированный по последовательностям кластерных меток. Тогда обучающая выборка имеет вид

$$\mathcal{D} = \{(x^{(i)}, y^{(i)})\}_{i=1}^N,$$

а задача классификации заключается в построении отображения

$$h : x \mapsto \hat{y} \in \{0, 1\}^L,$$

которое по признаковому описанию записи прогнозирует весь вектор меток одновременно.

Кластерное признаковое описание записи

Идея представления сердечного сигнала через последовательности дискретных состояний согласуется с литературой по символическому анализу ЭКГ. В частности, в работе Huang et al. [12] после символизации динамики RR -интервалов анализируются короткие паттерны и их частоты. Для настоящей работы этот результат важен как подтверждение того, что компактные статистики последовательности могут сохранять диагностическую информативность. Однако практическая схема текущей работы опирается не на кластеризацию RR -интервалов, а на отдельные последовательности морфологических состояний P -, QRS - и T -сегментов.

Пусть для фиксированного типа волны $W \in \{P, QRS, T\}$ задана последовательность кластерных меток

$$c^{(W)} = (c_1^{(W)}, c_2^{(W)}, \dots, c_{M_W}^{(W)}), \quad c_t^{(W)} \in \mathcal{C}_W,$$

где $\mathcal{C}_W$ — множество кластеров соответствующего типа сегмента. Тогда для любого кластера $a \in \mathcal{C}_W$ естественно определить абсолютную частоту

$$n_a(c^{(W)}) = \sum_{t=1}^{M_W} \mathbf{1}(c_t^{(W)} = a)$$

и относительную долю

$$\pi_a(c^{(W)}) = \frac{1}{M_W} \sum_{t=1}^{M_W} \mathbf{1}(c_t^{(W)} = a).$$

Наряду с ними используются бинарные индикаторы наличия кластера в записи,

$$I_a(c^{(W)}) = \mathbf{1}(n_a(c^{(W)}) > 0),$$

которые позволяют отделять факт появления морфологии от её относительной частоты.

Для учёта локальных порядковых зависимостей используются биграммы кластерных переходов. Для пары кластеров $(a, b) \in \mathcal{C}_W^2$ вводится частота перехода

$$n_{ab}(c^{(W)}) = \sum_{t=1}^{M_W-1} \mathbf{1}(c_t^{(W)} = a, c_{t+1}^{(W)} = b)$$

и соответствующая нормированная доля

$$\pi_{ab}(c^{(W)}) = \frac{n_{ab}(c^{(W)})}{M_W - 1}.$$

Важное уточнение состоит в том, что в текущей реализации используются именно биграммы кластерных переходов; триграммы и более длинные паттерны в итоговое признаковое описание не включаются.

Помимо частотных и биграммных характеристик, вектор $x^{(i)}$ дополняется статистиками signed-energy, признаками наличия импутированных сегментов и отношениями знакоориентированных амплитудных характеристик между типами волн. Тем самым окончательное описание записи сочетает частотную, порядковую и амплитудную информацию, но остаётся конечным и интерпретируемым.

Единое многометочное решающее дерево

В настоящей работе финальный классификатор реализован как единое многометочное решающее дерево. Каждому внутреннему узлу сопоставляется разбиение текущего множества объектов D на левое и правое подмножества D_L и D_R по одному из признаков вектора x . В листе дерева хранится не одна метка, а вектор вероятностей по всем диагностическим суперклассам,

$$\hat{p}_j(D) = \frac{1}{|D|} \sum_{i \in D} y_j^{(i)}, \quad j = 1, \dots, L.$$

После обхода дерева эти вероятности бинаризуются по выбранным порогам.

Ключевым вопросом является выбор критерия расщепления. Для каждого диагностического суперкласса j на множестве объектов D определяется доля положительных примеров

$$p_j(D) = \frac{1}{|D|} \sum_{i \in D} y_j^{(i)}.$$

Далее для каждого суперкласса вводится покомпонентный индекс Джини

$$G_j(D) = p_j(D)(1 - p_j(D)).$$

На его основе определяется величина стабильности

$$s_j(D) = 1 - 4G_j(D) = 1 - 4p_j(D)(1 - p_j(D)).$$

Она обращается в единицу на полностью однородном узле и уменьшается при росте смешанности по соответствующей метке.

Для агрегирования информации по всем меткам используется функционал

$$S(D) = \frac{1}{2} \left(\prod_{j=1}^L s_j(D) + \frac{1}{L} \sum_{j=1}^L s_j(D) \right).$$

Первое слагаемое штрафует разбиения, при которых хотя бы по одной метке сохраняется сильная неоднородность, а второе фиксирует среднюю степень упорядоченности по всем суперклассам. Для конкретного разбиения $D \rightarrow (D_L, D_R)$ качество задаётся выражением

$$\text{Score}(D_L, D_R) = \frac{|D_L|}{|D|} S(D_L) + \frac{|D_R|}{|D|} S(D_R).$$

Выбирается разбиение, максимизирующее $\text{Score}(D_L, D_R)$.

Связанные многометочные древовидные методы

В литературе предложены и другие подходы к построению многометочных деревьев. В работе Stepišnik et al. [14] рассматриваются option predictive clustering trees, в которых дерево также строится в многометочной постановке. В работе Al-Otaibi, Kull и Flach [15] предлагается критерий LaCova, который явно учитывает ковариации между метками. Эти методы важны как теоретический контекст, однако в настоящей работе используется более классическое многометочное дерево с описанным выше критерием стабильности, поскольку оно непосредственно согласовано с текущим кластерным признаковым пространством и остаётся интерпретируемым.

Бустинговые деревья как смежный ориентир

Хотя в настоящей работе основной акцент делается на одиночном интерпретируемом дереве, полезно отметить, что древовидные методы в более сложной ансамблевой форме уже показали эффективность на ЭКГ. В статье Ye, Huang и Lu [16] XGBoost используется как финальный модуль объединения для автоматической классификации многоканальной ЭКГ после извлечения пространственно-временных признаков. Это подтверждает, что древовидные модели в целом применимы к задачам автоматического анализа ЭКГ. Вместе с тем бустинговые ансамбли существенно менее интерпретируемы, чем одно дерево решений, поэтому в настоящей работе они рассматриваются лишь как внешний ориентир, а не как основной инструмент.

Глава 4

Практическая схема предлагаемого подхода

В предыдущих главах были рассмотрены теоретические основы сегментации ЭКГ, кластеризации морфологии сердечных циклов и последующей классификации записей. Настоящая глава посвящена тому, как эта схема реализуется в вычислительном эксперименте. Поэтому далее описывается не идеализированная теоретическая конструкция, а вычислительно оптимизированная форма подхода.

При этом сохраняется общая логика метода — сегментация, кластеризация, классификация, — однако на каждом этапе вводятся инженерные адаптации, направленные на устойчивость алгоритма, ограничение размерности признакового пространства и воспроизводимость эксперимента. Именно эти практические решения и составляют содержание настоящей главы.

Исходные данные и формирование меток

В качестве исходного материала используется открытая база РТВ-XL [9]. Каждая запись представляет собой 12-канальный ЭКГ-сигнал фиксированной длительности с частотой дискретизации 100 или 500 (выбрана для работы первая), а диагностическая разметка хранится в поле `scp_codes`. Для построения целевой переменной SCP-коды сопоставляются со справочной таблицей `scp_statements.csv`, после чего из всей аннотации сохраняются только диагностические утверждения, удовлетворяющие условию `diagnostic==1`. Далее эти утверждения агрегируются до укрупнённого поля `diagnostic_class`.

Поскольку одна запись может одновременно содержать признаки нескольких состояний, задача изначально формулируется в многометочной постановке. В вычислительном эксперименте рассматриваются все пять диагностическим суперклассов (наиболее крупные объединения синдромов по физиологической схожести, имеющиеся в РТВ-XL): NORM — нормальная ЭКГ без патологий; MI — инфаркт миокарда; STTC — изменения сегмента ST и зубца T; CD — нарушения проводимости; HYP — гипертрофия отделов сердца.

Разбиение выборки выполняется по стандартному полю `strat_fold`: фолды 1–8 используются для обучения, фолд 9 — для валидации, а фолд 10 — для итого-

вого тестирования. Такая схема соответствует общепринятому протоколу работы с РТВ-XL и сохраняет сопоставимость результатов между этапами вычислительного эксперимента.

Практическая сегментация ЭКГ

Теоретической основой этапа делинеации служат идеи вейвлет-подхода Li, Zheng и Tai [6], поскольку именно они мотивируют поиск не только R -пиков, но и полной структуры P – QRS – T . Однако в практической части работы реализовано не буквальное воспроизведение исходного алгоритма, а его вычислительно устойчивое инженерное приближение на основе стационарного вейвлет-преобразования. Тем самым в главе рассматривается практическая SWT-адаптация идей Li–Zheng–Tai, согласованная с общей схемой делинеации из работы *ECG Signal Analysis based on the Wavelet Transform* [3].

Для делинеации из исходной 12-канальной записи сначала выделяются грудные отведения

$$\mathcal{V} = \{V1, V2, V3, V4, V5, V6\}.$$

По ним строится один усреднённый сигнал

$$\bar{x}(t) = \frac{1}{6} \sum_{\ell \in \mathcal{V}} x_{\ell}(t),$$

после чего дальнейший поиск характерных точек выполняется именно на этом одномерном представлении. Усреднённый грудной сигнал используется как единая временная опора для последующего анализа записи.

Вейвлет-анализ выполняется с помощью стационарного вейвлет-преобразования `pywt.swt` с вейвлетом `bior2.2` и пятью уровнями разложения. В практической реализации вычисляются масштабы `scale2`, `scale4`, `scale8`, `scale16` и `scale32`; основная логика детекции, с учётом разницы с в 2.5 раза в частоте дискретизации у исходного датасета и датасета из статьи [6], опирается на `scale2`, `scale4`, `scale8` и `scale16`, тогда как `scale32` используется лишь как вспомогательный сглаженный уровень и не является ключевым масштабом принятия решений. Такой выбор не совпадает с классической схемой Mallat/DWT в строгом виде, но оказывается удобным для делинеации, поскольку SWT сохраняет длину сигнала на каждом уровне разложения и тем самым упрощает локализацию временных точек ЭКГ.

На усреднённом сигнале сначала определяются R -пики и границы комплекса QRS , после чего в фиксированных и поисковых окнах до и после QRS эвристически уточняются положения волн P и T . Следовательно, в практической реализации делинеация не трактуется как независимая клиническая разметка каждой волны в каждом отведении. Её роль состоит в том, чтобы построить согласованные временные окна на одном опорном сигнале и затем перенести найденные границы на исходную многоканальную запись для извлечения информативных фрагментов.

Извлечение P -, QRS - и T -сегментов

После завершения делинеации из исходного 12-канального сигнала извлекаются сегменты трёх типов: P , QRS и T . Для каждого типа волны $W \in \{P, QRS, T\}$ каждому сердечному циклу сопоставляется многоканальный фрагмент

$$X_j^{(W)} \in \mathbb{R}^{12 \times d_W},$$

где d_W — фиксированная длина сегмента данного типа. Тем самым дальнейшая кластеризация строится не по усреднённому грудному сигналу, а по многоканальным фрагментам исходной ЭКГ, отражающим морфологию соответствующей волны во всех 12 отведениях.

В практической реализации длины сегментов стабилизируются. Для каждого типа волны выбирается типичная, фактически медианная длина соответствующего фрагмента, после чего сегмент приводится к фиксированному размеру. Кроме того, вокруг основного окна сохраняется небольшой временной контекст, чтобы на этапе сравнения с прототипами можно было допускать малый локальный сдвиг и тем самым точнее совмещать морфологию фрагментов.

Если границы P - или T -волны определить не удаётся, соответствующий сердечный цикл не отбрасывается. Вместо этого строится техническое окно фиксированной длины: для отсутствующей P -волны — непосредственно перед QRS -комплексом, для отсутствующей T -волны — непосредственно после него. Этот приём позволяет не разрушать структуру признакового описания записи.

Корреляционная кластеризация морфологии

Кластеризация выполняется отдельно для P -, QRS - и T -сегментов. Для каждого типа волн формируются собственные множества кластеров $\mathcal{C}_P$, $\mathcal{C}_{QRS}$ и $\mathcal{C}_T$. Используемый алгоритм представляет собой корреляционную кластеризацию с прототипами, стабилизированную дополнительным критерием signed-energy.

Для оценки морфологического сходства двух многоканальных сегментов сначала по каждому из 12 каналов вычисляется коэффициент корреляции Пирсона

$$\rho(u, v) = \frac{\sum_{m=1}^d (u_m - \bar{u})(v_m - \bar{v})}{\sqrt{\sum_{m=1}^d (u_m - \bar{u})^2} \sqrt{\sum_{m=1}^d (v_m - \bar{v})^2}}.$$

Если для пары сегментов получены поканальные значения $\rho_1, \dots, \rho_{12}$, то после сортировки

$$\rho_{(1)} \leq \rho_{(2)} \leq \dots \leq \rho_{(12)}$$

в качестве итоговой меры сходства используется не строгий минимум, а порядковая статистика

$$C_{\text{ord}} = \rho_{(q)}.$$

Тем самым теоретически более жёсткий критерий минимума по каналам в реализации заменяется смягчённой порядковой мерой. При обучении кластерных

прототипов использовалась пятая порядковая статистика корреляций по каналам. На этапе последующего назначения сегментов к уже построенным прототипам при формировании признакового описания используется вторая порядковая статистика корреляций по каналам. Такое разделение отражает различие между более мягким построением устойчивых прототипов и более строгим назначением сегментов к фиксированному набору кластеров. Инвариантность корреляционной меры к постоянному сдвигу обеспечивается центрированием, входящим в вычисление коэффициента Пирсона. Допустимые отклонения задаются как $\Delta_P = 0.12$, $\Delta_{QRS} = 0.25$ и $\Delta_T = 0.15$ секунд.

При сопоставлении нового сегмента с уже построенным прототипом требуется выполнение корреляционного условия. Корреляционное условие имеет вид

$$C_{\text{ord}} \geq 0.8,$$

Одной корреляции недостаточно для полного описания сегмента, поскольку она характеризует прежде всего сходство формы после центрирования и не отражает знак преобладающего отклонения. Поэтому наряду с кластерной меткой для каждого сегмента вычисляется signed-energy — дополнительная амплитудно-знаковая характеристика, которая в компактной записи может быть определена как $\eta(X) = \text{mean}(X|X|)$ и в развёрнутом виде равна

$$\eta(X_j^{(W)}) = \frac{1}{12d_W} \sum_{\ell=1}^{12} \sum_{m=1}^{d_W} X_{j,\ell}^{(W)}(m) |X_{j,\ell}^{(W)}(m)|.$$

Величина $\eta(X_j^{(W)})$ сохраняет знак преобладающего отклонения и потому используется как дополнительный признак, позволяющий различать, например, элевацию и депрессию при близкой общей форме сигнала. Эта величина не является обычной энергией сигнала; в настоящей работе её корректнее трактовать как знакоориентированную амплитудную характеристику сегмента.

Для защиты устойчивых прототипов от выбросов вводится порог корреляционного отсека, равный 0.35. Если максимальное сходство нового сегмента со всеми уже построенными прототипами остаётся ниже этого уровня, сегмент рассматривается как редкий, шумовой или морфологически нестабильный и не используется для загрязнения основных кластеров. Дополнительно вводятся жёсткие ограничения на число кластеров: не более 10 для P -волн, не более 8 для QRS -комплексов и не более 10 для T -волн. Эти ограничения уменьшают размерность последующего признакового пространства и делают итоговую классификационную задачу более устойчивой и намного менее вычислительно затратной. Если после достижения лимита требуется перераспределение сегментов, то среди четырёх наименьших по размеру кластеров находится кластер, наиболее удалённый от остальных, и перераспределяется по ним. Это позволяет так же стабилизировать кластеризацию и сделать её более адаптивной в ограниченных условиях.

Построение признакового описания записи

В практической реализации непосредственным входом итогового классификатора служит агрегированное табличное описание записи. Для каждого сигнала строится последовательность кластерных меток и их signed-energy

$$c = (c_1^{(W_i)}, c_2^{(W_j)}, c_3^{(W_k)}, c_4^{(W_l)}, \dots, c_M^{(W)}) , \quad W_{i,j,k} \in \{P, QRS, T\},$$

после чего по этой последовательности формируются числовые признаки записи.

Для каждого кластера вычисляются доли кластера внутри записи, частоты, нормированные на число сердечных циклов, бинарные признаки присутствия и отсутствия кластера по малому фиксированному порогу присутствия. Для энергий вычисляется наличие отношений энергий соседних сегментов определённого типа (P, QRS, T) выше или ниже определённого порога и их среднее на записи. Тем самым последовательная информация переводится в конечное и контролируемое табличное представление.

Дополнительно строятся биграммы кластерных переходов, причём и отдельно для последовательностей P -, QRS - и T -сегментов. Триграммы в текущей реализации не используются и могут рассматриваться лишь как возможное расширение метода. Помимо частотных признаков, для каждого типа волны вычисляются статистики signed-energy — среднее, стандартное отклонение и медиана.

Таким образом, исходная идея последовательности кластерных состояний в реализации преобразуется в агрегированное табличное описание записи. На вход классификатора поступают частотные, бинарные, биграммные, signed-energy признаки.

Многометочное дерево решений

Финальная модель реализована как одно многометочное дерево решений. На вход модели подаётся матрица признаков

$$X \in \mathbb{R}^{N \times p},$$

а целевая переменная имеет вид

$$Y \in \{0, 1\}^{N \times L},$$

где L — число выбранных диагностических суперклассов. Следовательно, итоговая реализация не сводится к набору независимых бинарных классификаторов: каждое расщепление дерева строится с учётом сразу всех меток.

Если некоторому листу соответствует подмножество объектов D , то в нём хранится вектор вероятностей по всем меткам,

$$\hat{p}_j(D) = \frac{1}{|D|} \sum_{i \in D} y_j^{(i)}, \quad j = 1, \dots, L.$$

Тем самым процедура `predict_proba` возвращает матрицу вероятностей размера $N \times L$, после чего применяется пороговое преобразование.

Внутри дерева используется собственный критерий расщепления:

$$S(D) = \frac{1}{2} \left(\prod_{j=1}^L s_j(D) + \frac{1}{L} \sum_{j=1}^L s_j(D) \right),$$

а качество конкретного разбиения $D \rightarrow (D_L, D_R)$ задаётся выражением

$$\text{Score}(D_L, D_R) = \frac{|D_L|}{|D|} S(D_L) + \frac{|D_R|}{|D|} S(D_R).$$

Выбирается разбиение, максимизирующее $\text{Score}(D_L, D_R)$.

После получения матрицы вероятностей выполняется бинаризация предсказаний по порогу:

$$\hat{y}_{ij} = \mathbf{1}(\hat{p}_{ij} \geq \theta_j).$$

В простейшем случае используется общий скалярный порог, то есть $\theta_1 = \dots = \theta_L$. При более тонкой валидационной настройке архитектура классификатора допускает и вектор порогов, когда для разных диагностических суперклассов выбираются разные значения θ_j .

Выводы

Таким образом, практическая реализация предлагаемого подхода сохраняет общую трёхэтапную идею работы — сегментация, кластеризация, классификация, — но воплощает её через ряд технических адаптаций. Wavelet-делинеация выполняется по одному усреднённому сигналу, построенному по $V1-V6$, на основе стационарного вейвлет-преобразования с `bior2.2`; найденные временные границы затем используются для извлечения многоканальных P -, QRS - и T -фрагментов из исходной 12-канальной ЭКГ.

Дальнейшая кластеризация проводится отдельно по типам волн и основана на последовательном сравнении сегментов с прототипами по корреляции Пирсона, дополненной `signed-energy`. При этом на этапе обучения кластерных прототипов используется пятая порядковая статистика корреляций по каналам, а на этапе назначения сегментов к уже построенным прототипам при формировании признаков — вторая порядковая статистика. Дополнительно используются порог отсечения редких сегментов и жёсткие ограничения на число кластеров, что уменьшает чувствительность алгоритма к шуму и одновременно удерживает размерность признакового пространства под контролем.

Наконец, итоговая классификация выполняется не по единой последовательности совместных состояний, а по агрегированному табличному описанию записи, включающему частотные, бинарные, биграммные, `signed-energy` признаки. Финальный классификатор представляет собой одно многометочное дерево решений с векторными вероятностями в листьях.

Глава 5

Результаты вычислительного эксперимента и их обсуждение

В данной главе приводятся фактические результаты вычислительного эксперимента, полученные для практической схемы, описанной в главе 4. В центре внимания находятся не только итоговые показатели классификации, но и промежуточные результаты по этапам конвейера: внутренний контроль качества сегментации, сводка по морфологической кластеризации, размерность сформированного признакового пространства и сравнение конфигураций финального многометочного дерева решений.

Важно подчеркнуть, что проверка сегментации в настоящей главе не является полноценной клинической валидацией делинеации относительно экспертной разметки. Она используется как внутренний контроль качества перед этапом кластеризации и позволяет оценить, насколько стабильно строятся границы волн P , QRS и T в практическом конвейере.

Проверка качества сегментации

Внутренний контроль качества делинеации был проведён на подвыборке из 80 записей обучающей выборки. Для каждой записи оценивались число обнаруженных сердечных циклов, а также доля циклов, в которых удалось определить границы волн P и T . Сводные результаты приведены в табл. 5.1. Они показывают, что в среднем сегментационный этап обеспечивает высокое покрытие как для P -, так и для T -волн.

Лучшие примеры на контрольной подвыборке соответствовали записям 32, 45, 54, 80 и 113, для которых границы волн P и T были успешно определены во всех сердечных циклах. Наиболее проблемными оказались записи 101, 81, 66, 74 и 43. При этом основная нестабильность чаще проявлялась именно на этапе локализации P -волны: например, для записи 101 границы P -волны удалось определить лишь в 31.25% циклов при успешном определении границ T -волны в 93.75% цик-

Таблица 5.1: Внутренний контроль качества сегментации на подвыборке из 80 записей обучающей выборки

Показатель	Значение
Число записей в контрольной подвыборке	80
Число циклов на запись, среднее $\pm$ стандартное отклонение	11.825 ± 2.359
Число циклов на запись, min / median / max	7/11/20
Доля успешно найденных P -волн, среднее $\pm$ стандартное отклонение	0.944 ± 0.105
Доля успешно найденных T -волн, среднее $\pm$ стандартное отклонение	0.933 ± 0.179

лов, а для записи 81 — в 63.64% и 100% случаев соответственно.

На рис. 5.1 и 5.2 показаны два характерных примера многоканальной делинеации по грудным отведениям $V1-V6$. Первый отражает устойчивый случай, в котором границы циклов и положений волн согласованы от цикла к циклу; второй — проблемный случай, в котором общая структура записи сохраняется, но локализация слабых компонент оказывается заметно менее надёжной.

Дополнительное представление через усреднённый по грудным отведениям сигнал приведено на рис. 5.3. В записи 54 пики QRS и соседние интервалы для P - и T -волн повторяются почти периодически на протяжении 15 циклов, что соответствует идеальному внутреннему контролю: границы обеих волн определены во всех циклах. В записи 81, напротив, наблюдается более выраженная изменчивость базовой линии и формы предсердной активности; это согласуется с тем, что именно для P -волны внутренний показатель качества здесь заметно ниже.

Таким образом, сегментационный этап в среднем обеспечивает высокое покрытие волн P и T на контрольной подвыборке, однако слабые предсердные компоненты остаются наиболее уязвимым местом делинеации. Для последующих этапов это означает, что качество кластеризации сильно зависит от устойчивости локализации P -сегментов.

Результаты кластеризации морфологических сегментов

База РТВ-XL в исходной публикации описывается как набор из 21837 клинических 12-канальных ЭКГ-записей [9]. В вычислительном эксперименте после прикладного отбора использовалось 21430 записей: 17111 в обучающей части, 2156 в валидационной и 2163 в тестовой. Разница между полным объёмом базы и числом записей, вошедших в эксперимент, связана с фильтрацией записей, для которых не удалось сформировать корректное признаковое описание в рамках используемого конвейера.

После извлечения сегментов для этапа кластеризации были сформированы 202184 образца P -волн, 205342 образца QRS -комплексов и 200624 образца T -волн. Итоговая сводка по устойчивым кластерам приведена в табл. 5.2.

Полученные результаты позволяют сделать несколько содержательных выво-




Рис. 5.1: Пример устойчивой сегментации: запись 54 (суперкласс STTC), 15 циклов; границы волн P и T успешно найдены во всех циклах. Цветовые интервалы отражают найденные границы волн и комплексов.

Таблица 5.2: Сводка по кластеризации морфологических сегментов на обучающей выборке

Тип	Число образцов	Кластеров / лимит	Мин. размер	Макс. размер	Суммарный размер	Число редких сегментов	Отфильтровано
P	202184	10/10	145	133598	191428	7001	3755
QRS	205342	6/8	149	180705	204237	873	232
T	200624	10/10	159	126819	199727	292	605




Рис. 5.2: Пример проблемной сегментации: запись 101, 16 циклов; границы P -волн определены в 31.25% циклов, а границы T -волн — в 93.75%. Даже в этом случае сохраняется общая структура сердечных циклов, однако границы слабых волн определяются заметно менее стабильно.

дов. Во-первых, пространство морфологий *QRS* оказалось наиболее компактным: при лимите в восемь устойчивых кластеров практически значимая структура стабилизировалась уже на шести прототипах. Во-вторых, наибольшая доля редких объектов наблюдается у *P*-волн (3.46%), что согласуется с более высокой чувствительностью предсердной активности к ошибкам делинеации и локальным вариациям формы. Наконец, для *T*-сегментов доля редких сегментов минимальна, что указывает на достаточно устойчивое группирование реполяризационных морфологий в выбранном профиле признаков.

Для качественной иллюстрации на рис. 5.4 приведены по четыре характерных примера кластеров для каждого типа волн. Уже в этом компактном виде видно, что *P*-волны характеризуются более мягкими и низкоамплитудными отклонениями, *QRS*-кластеры демонстрируют наиболее локализованные и контрастные формы, а *T*-сегменты занимают промежуточное положение и различаются прежде всего плавной реполяризационной конфигурацией.


Построение признакового пространства

На этапе построения признакового описания лимиты числа кластеров были заданы как 10 для *P*-волн, 8 для *QRS*-комплексов и 10 для *T*-волн; по итогам кластеризации было получено соответственно 10, 6 и 10 устойчивых кластеров. Корреляционный порог сопоставления с прототипом был выбран равным 0.8, порог выделения редких сегментов — 0.35.


В признаковом описании использовались биграммы кластерных переходов, а не более длинные n -граммы. После фильтрации по условию минимум трёх сердечных циклов на запись были сформированы матрицы признаков размером 17021×388 для обучающей, 2151×388 для валидационной и 2150×388 для тестовой подвыборок; целевые матрицы имели размеры 17021×5 , 2151×5 и 2150×5 соответственно.

Среднее число циклов на запись оказалось близким на всех подвыборках: 12.066682 для обучающей, 12.115295 для валидационной и 12.070233 для тестовой. Это указывает на отсутствие заметного смещения по грубой ритмической сложности между подвыборками. В результате итоговое пространство из 388 признаков остаётся достаточно компактным для интерпретируемой древовидной модели, но при этом сохраняет информацию о частотах кластеров, биграммных переходах, signed-energy-статистиках.

Различие между числом записей, использованных при обучении кластерных прототипов, и числом строк итоговой обучающей матрицы признаков связано с разными условиями фильтрации на этих этапах. Для обучения кластеризации использовалось более строгое условие минимального числа сердечных циклов на запись, тогда как при построении признакового описания применялся менее жёсткий порог. Поэтому для обучения кластерных прототипов было успешно обработано 17006 обучающих записей, а итоговая обучающая матрица признаков содержит 17021 строку.



(a) Усреднённый по грудным отведениям сигнал для записи 54 (суперкласс STTC), 15 циклов.



(b) Усреднённый по грудным отведениям сигнал для записи 81, 11 циклов.

Рис. 5.3: Сопоставление усреднённого сигнала по грудным отведениям для устойчивого и проблемного примеров сегментации.




Рис. 5.4: Примеры устойчивых морфологических кластеров: для каждого типа волн показано по четыре характерных фрагмента вместо полного набора центров.

Сравнение конфигураций дерева

В ходе обучения сравнивались несколько конфигураций единого многометочного дерева решений. Их выбор выполнялся по внешнему валидационному критерию $\prod_{j=1}^L (F1_j + 0.01)$, который не совпадает с внутренним критерием расщепления дерева, описанным в главе 4. Результаты сравнения приведены в табл. 5.3.

Таблица 5.3: Сравнение конфигураций многометочного дерева по внешнему валидационному критерию

Конфигурация	$\prod_{j=1}^L (F1_j + 0.01)$ на валидационной выборке
Расширенная, глубина 32	0.403152
Расширенная, глубина 16	0.382410
Базовая, глубина 10	0.354228
Расширенная, глубина 8	0.311504
Базовая, глубина 8	0.285416
Базовая, глубина 6	0.224173

Рассматривать конфигурации без энергитической составляющей (базовая) и с ней (расширенная). Лучшей по внешнему валидационному критерию оказалась расширенная конфигурация дерева. В целом рост глубины и расширение внутреннего пространства разбиений сопровождалось улучшением этого критерия. Вместе с тем различия между несколькими верхними конфигурациями уже не столь велики, что указывает на частичное насыщение эффекта при дальнейшем усложнении дерева.

Финальные результаты классификации

В качестве итоговой рассматривается расширенная конфигурация многометочного дерева, выбранная по внешнему валидационному критерию. В финальном эксперименте использовались следующие параметры дерева: $max_depth = 12$, $min_samples_split = 34$, $min_samples_leaf = 27$, $max_features = 0.6$, $max_splits_per_feature = 12$. Бинаризация вероятностных выходов выполнялась по покомпонентным порогам для диагностических суперклассов. Общие метрики на обучающей, валидационной и тестовой подвыборках приведены в табл. 5.4.

Таблица 5.4: Общие метрики многометочной классификации на всех выборках

Выборка	N	Полное совп.	Покомп. точн.	Точность	Полнота	F_1
Обучающая	17021	0.724	0.941	0.835	0.912	0.872
Валидационная	2151	0.685	0.922	0.794	0.888	0.838
Тестовая	2150	0.672	0.915	0.781	0.876	0.825

Здесь «полное совпадение меток» соответствует subset accuracy и требует правильного предсказания всего многометочного вектора записи, а «покомпонентная

точность» соответствует Hamming accuracy и оценивает среднюю правильность по отдельным компонентам вектора меток.

Для тестовой выборки дополнительно приведены матрицы ошибок по каждому диагностическому суперклассу, показанные на рис. 5.5. По ним рассчитываются покомпонентные показатели, приведённые в табл. 5.5. Для наглядности используются две вспомогательные характеристики:

$$G\text{-мера}_j = \sqrt{\text{precision}_j \cdot \text{recall}_j}, \quad G\text{-среднее}_j = \sqrt{\text{recall}_j \cdot \text{specificity}_j}.$$

Таблица 5.5: По-классовые метрики на тестовой выборке (пересчитанные)

Суперкласс	TP	TN	FP	FN	Точность	Полнота	Специфичность	F_1	G-мера	G-среднее
NORM	918	1051	138	43	0.869	0.955	0.884	0.910	0.911	0.919
MI	484	1420	182	64	0.727	0.883	0.886	0.797	0.801	0.885
STTC	468	1531	102	49	0.821	0.905	0.938	0.861	0.862	0.921
CD	423	1534	123	70	0.775	0.858	0.926	0.814	0.815	0.891
HYP	201	1810	81	58	0.713	0.776	0.957	0.743	0.744	0.862


Анализ результатов

На тестовой выборке качество модели снижается по сравнению с валидационной, однако характер этого снижения неоднороден. Средняя F_1 -мера по пяти диагностическим суперклассам уменьшается с 0.838 до 0.825, Hamming accuracy — с 0.922 до 0.915, а subset accuracy — с 0.685 до 0.672. Следовательно, между валидационной и тестовой подвыборками имеется заметный generalization gap.


Различие между Hamming accuracy и subset accuracy особенно важно для многометочной постановки. Hamming accuracy оценивает правильность отдельных компонент вектора меток, тогда как subset accuracy требует полного совпадения всего многометочного вектора записи. Поэтому полученные значения показывают, что модель существенно лучше предсказывает отдельные диагностические суперклассы, чем полностью восстанавливает их совместные комбинации.

По-классовый анализ показывает выраженную неоднородность качества. Наиболее уверенно распознаётся суперкласс NORM: высокая полнота 0.955 сочетается с F_1 -мерой 0.910, однако специфичность 0.884 указывает на заметное число ложноположительных предсказаний нормы. Среди патологических суперклассов наиболее сбалансированные результаты получены для STTC: F_1 -мера 0.861 сочетается с полнотой 0.905 и специфичностью 0.938. Для MI и CD качество ниже и остаётся умеренным, что указывает на недостаточную выразительность текущего признакового пространства для устойчивого разделения соответствующих морфологических паттернов.


Наиболее трудным суперклассом является HYP. Для него достигнута высокая специфичность 0.957, однако полнота составляет только 0.776, а F_1 -мера — 0.743.



(a) Норма - NORM




(b) Инфаркт миокарда - MI



(c) Изменения сегмента ST и зубца T - STTC



(d) Нарушения проводимости - CD



(e) Гипертрофия - HYP

Рис. 5.5: Матрицы ошибок на тестовой выборке для пяти суперклассов.

Такая асимметрия означает, что модель сравнительно редко ошибочно приписывает гипертрофию там, где её нет, но часто пропускает реальные положительные случаи. Следовательно, именно НУР в текущей постановке является главным ограничивающим суперклассом. Однако модель ввиду достаточно высокого качества детекции NORM определяет запись как имеющую отклонения.

В целом предложенная схема демонстрирует работоспособность и интерпретируемость, однако её качество правильнее характеризовать как умеренное и неоднородное по суперклассам. Текущий набор признаков хорошо выделяет норму и часть реполяризационных изменений, но недостаточно полно отражает вариативность гипертрофии, нарушений проводимости и части инфарктных паттернов. Следовательно, дальнейшее улучшение модели должно быть связано не столько с механическим усложнением дерева, сколько с усилением признакового описания, уточнением процедуры назначения сегментов к кластерам, калибровкой порогов по отдельным суперклассам и более строгим учётом совместной структуры многометочных диагнозов.

Ограничения и выводы по результатам

При интерпретации полученных результатов необходимо учитывать несколько ограничений. Во-первых, сегментация P - и T -волн не является идеальной и в ряде случаев требует технической подстановки окон. Во-вторых, анализ ограничен пятью наиболее частыми диагностическими суперклассами РТВ-XL, включающие и редкие синдромы. В-третьих, был наложен ряд ограничений для уменьшения вычислительной сложности.

В целом результаты главы показывают, что сегментационный этап пригоден как внутренний шаг подготовки данных к кластеризации, морфологическая кластеризация формирует компактное и интерпретируемое пространство состояний, а пространство из 388 признаков оказывается информативным для многометочной древовидной классификации. Вместе с тем достигнутое качество может позволить упростить первичный анализ и сделать акцент на дефектах записи.

Заключение

Целью данной работы являлась разработка интерпретируемого подхода к автоматическому распознаванию многометочных диагностических суперклассов по 12-канальной ЭКГ на основе последовательного перехода от исходного сигнала к сегментированным волновым фрагментам, далее к их морфологическим кластерам и затем к табличному признаковому описанию записи.

В ходе исследования была реализована практическая схема, включающая SWT-делинеацию по усреднённому сигналу грудных отведений $V1-V6$, извлечение многоканальных P -, QRS - и T -сегментов, отдельную корреляционную кластеризацию с прототипами и учётом signed-energy, построение пространства из 388 интерпретируемых признаков и обучение единого многометочного дерева решений для пяти диагностических суперклассов PTB-XL: NORM, MI, STTC, CD и NYP.

Полученные результаты показывают работоспособность предложенной схемы в исследовательской постановке. На тестовой выборке достигнуты subset accuracy 0.672, Hamming accuracy 0.915, точность 0.781, полнота 0.876 и F1-мера 0.825. Наиболее уверенно модель распознаёт норму и суперкласс STTC, тогда как для MI, CD и особенно NYP качество остаётся заметно ниже. Тем самым итоговую модель следует характеризовать как интерпретируемую и содержательно работоспособную, но не как готовую к клиническому применению систему.

Дальнейшее развитие работы целесообразно связывать с усилением признакового описания записи, более строгим учётом совместной структуры многометочных диагнозов, калибровкой порогов по отдельным суперклассам и расширением внешней валидации метода. Таким образом, предложенная схема представляет собой интерпретируемую основу для дальнейших исследований в области автоматического анализа 12-канальной ЭКГ.

Литература

- [1] J. R. Hampton. *The ECG Made Easy*. 7th ed. London: Churchill Livingstone Elsevier; 2008.
- [2] H. Y. Mir, O. Singh. ECG denoising and feature extraction techniques — a review. *Journal of Medical Engineering & Technology*. 2021;45(8):672–684. DOI: 10.1080/03091902.2021.1955032.
- [3] C. Böck. *ECG Signal Analysis based on the Wavelet Transform*. Master’s thesis. Graz University of Technology; 2015. URL: <https://diglib.tugraz.at/ecg-signal-analysis-based-on-the-wavelet-transform-2015>.
- [4] S. Mallat. A theory for multiresolution signal decomposition: the wavelet representation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*. 1989;11(7):674–693. DOI: 10.1109/34.192463.
- [5] I. I. Christov. Real time electrocardiogram QRS detection using combined adaptive threshold. *BioMedical Engineering OnLine*. 2004;3:28. DOI: 10.1186/1475-925X-3-28.
- [6] C. Li, C. Zheng, C. Tai. Detection of ECG characteristic points using wavelet transforms. *IEEE Transactions on Biomedical Engineering*. 1995;42(1):21–28. DOI: 10.1109/10.362922.
- [7] J. Pan, W. J. Tompkins. A real-time QRS detection algorithm. *IEEE Transactions on Biomedical Engineering*. 1985;32(3):230–236. DOI: 10.1109/TBME.1985.325532.
- [8] R. Ceylan. ECG Arrhythmia Classification Using Vague C-Means Clustering Based on Multiresolution Analysis. *Traitement du Signal*. 2025;42(1):495–504. DOI: 10.18280/ts.420142.
- [9] P. Wagner, N. Strodthoff, R.-D. Bousseljot et al. PTB-XL, a large publicly available electrocardiography dataset. *Scientific Data*. 2020;7:154. DOI: 10.1038/s41597-020-0495-6.
- [10] H. Liu, D. Chen, D. Chen, X. Zhang, H. Li, L. Bian, M. Shu, Y. Wang. A large-scale multi-label 12-lead electrocardiogram database with standardized diagnostic statements. *Scientific Data*. 2022;9:272. DOI: 10.1038/s41597-022-01403-5.

- [11] J. Lai, Y. Zhang, C. Zhao et al. Multi-expert ensemble ECG diagnostic algorithm using mutually exclusive–symbiotic correlation between 254 hierarchical multiple labels. *npj Cardiovascular Health*. 2024;1:8. DOI: 10.1038/s44325-024-00010-0.
- [12] Y.-C. Huang, H. Lin, Y.-L. Hsu, J.-L. Lin. Using n-gram analysis to cluster heartbeat signals. *BMC Medical Informatics and Decision Making*. 2012;12:64. DOI: 10.1186/1472-6947-12-64.
- [13] F. Plesinger, J. Jurco, J. Halamek, P. Leinveber, T. Reichlova, P. Jurak. Multichannel QRS Morphology Clustering: Data Preprocessing for Ultra-High-Frequency ECG Analysis. In: *Proceedings of CARDIOTECHNIX 2015 – International Congress on Cardiovascular Technologies*. 2015. DOI: 10.5220/0005604200110019.
- [14] T. Stepišnik, D. Kocev, S. Džeroski. Option Predictive Clustering Trees for Multi-label Classification. *Acta Polytechnica Hungarica*. 2020;17(10):109–128. DOI: 10.12700/APH.17.10.2020.10.7.
- [15] R. Al-Otaibi, M. Kull, P. Flach. LaCova: A Tree-Based Multi-Label Classifier Using Label Covariance as Splitting Criterion. In: *2014 13th International Conference on Machine Learning and Applications*. 2014:74–79. DOI: 10.1109/ICMLA.2014.17.
- [16] X. Ye, Y. Huang, Q. Lu. Automatic Multichannel Electrocardiogram Record Classification Using XGBoost Fusion Model. *Frontiers in Physiology*. 2022;13:840011. DOI: 10.3389/fphys.2022.840011.